

# Ampirik Kip Ayrışımı Yoluyla Epileptik Nöbet Teşhisi Seizure Detection via Empirical Mode Decomposition

Nilüfer Özdemir, Fırat Duman

Esen Yıldırım

Elektrik-Elektronik Mühendisliği Bölümü  
Mustafa Kemal Üniversitesi

n\_sarpkaya\_ozdemir,firatduman63@hotmail.com

Bilgisayar Mühendisliği Bölümü  
Mustafa Kemal Üniversitesi

eyildirim@mku.edu.tr

## ÖZETÇE

*Epilepsi dünya çapında çok sayıda insanı etkileyen nörolojik bir hastalıktır. Epilepsi teşhisinde, EEG işaretleri kullanılarak epileptik nöbet tahmini yapılması önemli bir yer tutmaktadır. Bu çalışmada, nöbet tespiti için Ampirik Kip Ayrışımı (AKA) tabanlı bir yöntem önerilmektedir. Öncelikle EEG verileri İçsel Mod Fonksiyonlarına (İMF) ayrılmakta ve ilk 4 İMF'nin en küçük, en büyük, ortalama, standart sapma ve enerji değerleri alınarak sınıflandırıcıya gönderilmektedir. Önerilen yöntem, 123 dakikalık nöbet verisi ve 200 dakikalık nöbet dışı veri üzerinde, 3 farklı sınıflandırıcı kullanılarak test edilmiştir. Tüm sınıflandırıcılar için %80 üzerinde duyarlılık ve %95 üzerinde belirlilik elde edilmiştir. Bu sonuçlar, epilepsi teşhisinde AKA yöntemi kullanımının ümit verici olduğunu göstermektedir.*

## ABSTRACT

*Epilepsy is a neurological disorder that affects a serious number of people all around the world. Detection of epileptic seizures using EEG signals occupies an important part in the diagnosis of epilepsy. The aim of this study is to develop a method for seizure detection based on Empirical Mode Decomposition. In this method, EEG signals are decomposed to their Intrinsic Mode Functions and first 4 IMF's maximum, minimum, mean, standard deviation and energy values are used for classification. This method was tested on 123 minutes of ictal data and 200 minutes of inter-ictal data using 3 different classifiers. For all classifiers, over %80 sensitivity and over %95 specificity were obtained. These results show that epileptic seizure detection in EEG records via EMD is very promising.*

## 1. GİRİŞ

Dünya nüfusunun %3'ünü, Türkiye nüfusunun yaklaşık %1'ini etkileyen epilepsi, bilinen en yaygın nörolojik bozukluktur. Epilepsi, hastayı sadece nöbet anlarında rahatsız eden, bunun dışında normal yaşamına devam etmesini engellemeyen bir hastalıktır. Epileptik nöbet, beyin içerisinde bir grup sinir hücrelerinin normal olmayan yoğun boşalımı sonucunda ortaya çıkan durumdur. Epilepsi tanısında, nöbet algılama önemli bir bileşendir. Bu tanı, genellikle uzun EEG kayıtlarının uzman hekimler tarafından görsel olarak taranması ile konulur. Bu çok zaman alıcı ve hata oranı yüksek bir yöntemdir. Bu nedenle, EEG sinyallerinin otomatik algoritmalar kullanılarak bilgisayarla analiz edilmesi, bu hastalığın tanısı için çok önemlidir.

EEG işaretleri, dinamik, stokastik, doğrusal olmayan (nonlinear), durağan olmayan (nonstationary), aynı zamanda önemli derecede karmaşık davranış sergileyen kendiliğinden oluşan elektriksel beyin aktiviteleridir. Veri analizinde, Fourier Dönüşümü ve Dalgacık Dönüşümü gibi geleneksel yöntemler kullanıldığında, zaman serisi verilerinin durağan ve/veya doğrusal oldukları varsayımı yapılmaktadır. Bu analizlerin EEG verilerine uygulanması durumunda, verilerdeki doğrusal olmayan karakteristikler gözardı edilmekte, işaretin yalnızca doğrusal dinamikleri incelenmektedir. 90'lı yılların sonlarına doğru Norden E. Huang tarafından önerilmiş olan AKA yöntemi hem doğrusal hem de durağan olmayan işaretlerin analizine imkan veren adaptif ve etkili bir yöntemdir [1]. AKA yöntemiyle, işaret her biri tek elemanlı (monocomponent), diğer bir deyişle en küçük zaman biriminde tek frekans içeriğine sahip, sınırlı sayıda fonksiyona ayrılır. Bu fonksiyonlar İMF olarak adlandırılırlar. AKA yönteminin EEG işaretlerine uygulanmasıyla, bu işaretlerin eksiksiz olarak incelenmesi mümkündür. AKA yöntemi, biyomedikal işaret işleme alanında pek çok çalışmada kullanılmıştır. Elektrokardiyogram (EKG) verilerinin gürültüden arındırılması [2, 3], yüzey elektromiyografi (EMG) işaretlerinden öznelik çıkarılması [4], EMG işaretlerinin filtrelenmesi [5] ve şizofrenik EEG işaretlerindeki faz uyumu [6] bu çalışmalardan bazılarıdır. Son zamanlarda EEG işaretlerinden epilepsi tespitinde de AKA yöntemi kullanılmıştır [7, 8, 9].

Bu çalışmada, AKA yoluyla epileptik nöbet tespiti yapılması amaçlanmaktadır. Bu amaç doğrultusunda, nöbet ve nöbetler arası anlardaki epileptik EEG işaretlerinden İMF'ler elde edilmekte ve bu İMF'lerin ilk 4 tanesinden en büyük, en küçük, ortalama, standart sapma ve enerji değerleri kullanılarak sınıflandırma yapılmaktadır.

## 2. EEG Veri Tabanı

Bu çalışmada kullanılan EEG kayıtları, Freiburg Üniversite Hastanesi Epilepsi Merkezinde tıbbi açıdan zorlu olarak nitelendirilen hastalardan, invazif olarak alınan verilerden oluşmaktadır [10]. Veriler ameliyat öncesindeki epilepsi izleme kayıtlarıdır. Kayıt sonrasında herhangi bir filtreleme yapılmamıştır. Yüksek bir sinyal gürültü oranı elde etmek, bozulma etkilerini azaltmak ve direkt olarak bu yoğunlaşma bölgelerinden bilgi alabilmek amacıyla elektrotlarda bazı düzenlemelere gidilmiştir. Tüm elektrotlar arasından 6 tanesi, lisanslı bir epileptolog tarafından görsel inceleme yo-

luyla seçilmiştir. Bu 6 elektrottan üç tanesi epileptik nöbetin başlangıç bölgesinden, diğer bir deyişle erken iktal aktivitenin görüldüğü bölgelerden, kalan üç tanesi ise nöbet aktivitesinin gözlemlenmediği ya da nöbet ile en son ilişkilendirilebilecek bölgelerden seçilmiştir. Freiburg Veritabanı 21 hasta kaydı içermektedir. Bu çalışmada 21 hastadan, nöbet süreleri yeterli sayıda pencere elde edilebilecek kadar uzun olan, 12 hasta seçilmiştir.

## 2.1. Yöntem

Epileptik nöbet tahmini için kullanılacak sistem 4 adımdan oluşmaktadır. Bu adımlar EEG verilerinin gürültüden temizlenmesi, gürültüden temizlenmiş verilerin bölütlerine ayrılması, EEG bölütlerinden AKA yöntemi yardımıyla özniteliklerin elde edilmesi ve verilerin *Nöbet / Nöbet Değil* şeklinde sınıflandırılması şeklinde özetlenebilir.

### 2.1.1. Verilerin Gürültüden Temizlenmesi


EEG verilerindeki şebekeden kaynaklı gürültüyü ortadan kaldırmak için, 50 Hz band durdurucu filtre uygulanmıştır. Verilerdeki DC bileşen ve çok yavaş yapay olgular yüksek geçiren filtre (0.5 Hz) ile, yüksek frekanslı yapay olgular ise alçak geçiren filtre (120 Hz) ile filtrelenmiştir.

### 2.1.2. Verilerin Bölütlerine Ayrılması

Nöbet tahmininde kullanılacak öznitelikleri elde etmek için kayan pencere analizi yöntemi kullanılmıştır. Bu analiz yönteminde EEG verileri, önceden belirlenen uzunluktaki pencerelere bölünmekte, bu pencerelerden ölçüm/öznitelik çıkarımı yapılarak bir sonraki pencereye geçilmektedir. Kullanılan pencere uzunlukları 10 ile 40 sn arasında değişmekte ve istenilmesi halinde iç içe geçen pencereler (overlaped windows) kullanılmaktadır. Bu çalışmada 10 saniyelik pencereler ve 5 saniyelik kaydırmalar (%50 örtüşme) kullanılmıştır.

### 2.1.3. Ampirik Kip Ayrışımı

AKA doğrusal olmayan ve durağan olmayan işaretlere de uygulanabilen genel bir ayrıştırma yöntemidir. Bu yöntem sayesinde herhangi bir karmaşık veri seti sonlu sayıda (genellikle küçük bir rakam) İMF'ye ayrıştırılabilir. Bir İMF, basit bir salınım modunu simgeler. Bu açıdan Fourier Dönüşümünde kullanılan basit harmonik fonksiyonlar ile benzeşmektedir. Bir İMF, aynı sayıda ya da en fazla bir farklı sıfır geçişi ve uçdeğer değerlerine sahip bir fonksiyondur. Aynı zamanda yerel en büyük ve en küçük değerleri tarafından tanımlanan, sıfır noktasına göre simetrik zarflara sahip, herhangi bir fonksiyon olarak tanımlanabilir. Veri setinin İMF'lere ayrıştırılma işlemi adaptif bir yöntem olduğu için çok verimlidir ve verilerin zaman düzlemindeki yerel karakteristiklerine dayandığı için doğrusal olmayan ve durağan olmayan işlemlere uygulanabilir [1]. Her, doğrusal ya da doğrusal olmayan, içsel mod aynı sayıda uçdeğer ve sıfır geçişine sahip basit bir salınımı simgeler. Bunun yanında salınım yerel ortalamaya göre simetrik olmalıdır. Herhangi bir anda farklı salınım modları etkili olabilir. Bu salınımlar sonuç olarak karmaşık verileri oluşturur. Bu salınımlardan her biri aşağıdaki özellikleri sağlayan bir İMF ile simgelenir.



Şekil 1: Nöbet Anı EEG sinyali ve bu sinyalden elde edilen IMF'ler.

1. Tüm verisetinde, uçdeğer sayısı ile sıfır geçişi sayısı arasındaki fark en fazla bir olabilir.
2. Her hangi bir noktada, yerel en küçük değer ve yerel en büyük değer tarafından tanımlanan zarfın ortalama değerleri sıfır olmalıdır.

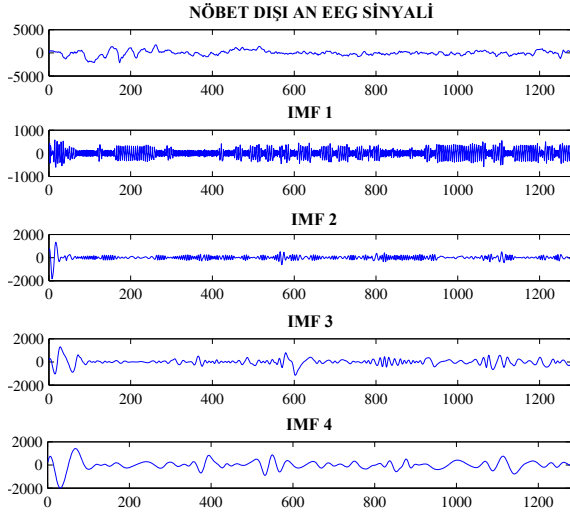
İMF'ler, karmaşık işareti oluşturan salınımlar olmaları sebebiyle, Fourier dönüşümünde kullanılan basit harmonik fonksiyonlar ile benzerlik gösterir. Ancak İMF'ler çok daha genel bir yapıya sahiptir. Örneğin basit harmonik bileşenlerde kullanılan sabit genlik ve frekans yerine, bir İMF zamana göre değişim gösteren genlik ve frekansa sahip olabilir. N adet İMF elde edildiği varsayılırsa, N-ampirik kip ve bir kalan şeklinde ayrıştırılmış olan işaret aşağıdaki şekilde ifade edilebilir:

$$x(t) = \sum_{i=1}^N g_i(t) + r_N \quad (1)$$

AKA yöntemi, medikal alanda, durağan olmayan sinyaller için gürültü temizliğinde başarılı uygulamalara sahiptir [11]. Bu yöntemde gürültü temizliği, genellikle elde edilen İMF'lerin son kısmının işaretten çıkarılarak yeniden toplanması ile yapılmaktadır. Tafreshi'nin bir çalışmasında epileptik nöbet tespitinde ilk 3, 4, 5 ve 6 İMF kullanılarak sınıflandırma yapılmış ve en başarılı sonuç ilk dört İMF kullanıldığında elde edilmiştir [12]. Bu çalışmada, AKA yöntemi sonucunda elde edilen N adet İMF'nin ilk dördünden elde edilen özniteliklere sınıflandırma yöntemleri uygulanarak epileptik nöbet tespiti yapılmıştır.

### Öznitelik Seçimi

Sınıflandırma için, hastaların epileptik nöbet başlangıç bölgesi olarak belirlenen 3 elektrottan elde edilen veriler kullanılmıştır. Her bir elektrottan elde edilen veriler gürültüden temizlenerek bölütlerine ayrılmış ve bu işaretler AKA yöntemi uygulanarak İMF'lerine ayrılmıştır. Bu İMF'lerden ilk 4 tanesi için en küçük, en büyük, ortalama, standart sapma ve enerji değerleri hesaplanarak her zaman dilimi için 60 elemanlı öznitelik vektörü elde edilmiştir. Şekil 1 ve 2'de nöbet anı ve nöbet dışı anlara ait 5 saniyelik EEG veri penceresi ve bunlardan elde edilen İMF'ler gösterilmiştir.



Şekil 2: Nöbet Dışı EEG sinyali ve bu sinyalden elde edilen IMF'ler.

#### 2.1.4. Sınıflandırma

Çalışmamızda K en yakın komşuluk (kNN), Destek Vektör Makineleri (DVM) ve Karar Ağaçları (KA) algoritmaları kullanılarak sınıflandırma yapılmıştır. Sınıflandırma işleminde, 10-katlı çapraz doğrulama işlemi kullanılmıştır. Bu işlemde, veriler rastgele olarak 10 eşit parçaya bölünür ve her defasında bir parça test için, geriye kalan 9 parça da eğitim için kullanılır. Böylece, eğitim-test işlemi 10 kere tekrarlanır. Sonuç olarak bireysel elde edilen 10 sonucun ortalaması alınır.

Sınıflandırıcı olarak kullanılan yöntemler aşağıda kısaca anlatılmaktadır.

##### K En Yakın Komşuluk

Bu yöntem, örüntü tanıma ve makine öğrenme algoritmaları içinde en basit olanıdır. kNN algoritması, sınıflandırılmak istenen herhangi bir özellik vektörünün eğitici veri setinde var olan ve daha önceden bir sınıfın elemanı olduğu bilinen diğer özellik vektörleriyle belirlenen bir kritere göre karşılaştırılarak, en yakın olanların daha çok bulunduğu sınıfa ait olarak etiketlenilmesi prensibine dayanmaktadır [13]. Karşılaştırma kriteri olarak genelde Öklid uzaklığı kullanılmaktadır. Bu algoritmadaki k; sınıflandırılmak istenen örneğe en yakın k adet komşuyu (eğitici veri kümesindeki diğer özellik vektörlerini) ifade etmektedir. Bu çalışmada k=1 kullanılmıştır.

##### Destek Vektör Makineleri

DVM, son yıllarda yaygın olarak kullanılan bir sınıflandırma algoritmasıdır. Temelde doğrusal olarak ayrıştırılabilir iki sınıfın karar yüzeyinin destek vektörler olarak tanımlanan ve sınıf sınırlarını belirleyen örnekler arasında en yüksek mesafe oluşturulması ilkesine dayanan bir algoritmadır. Mesafeyi en yükseğe çıkarma işlemi, karesel sınırlamalı optimizasyon problemi şeklinde yazılır ve ikili biçime dönüştürülür. Doğrusal problemler için geliştirilen bu yaklaşım doğrusal olmayan ayrıştırma problemleri için kernel dönüşümleri kullanılarak genelleştirilebilir [14].

##### Karar Ağaçları

KA, son yıllarda literatürde yaygın kullanımı olan bir sınıflandırma ve örüntü tanımlama algoritmasıdır. Bir ağaç yapısı; verileri içeren bir kök düğümü, iç düğümler (dallar)

Tablo 1: kNN Sınıflandırıcısı için Sonuçlar

h	DP	YN	YP	DN	Duy	Bel
3	74	10	1	199	0,88	1,00
4	79	1	0	200	0,99	1,00
7	70	17	6	194	0,80	0,97
8	40	22	16	184	0,65	0,92
9	104	2	1	199	0,98	1,00
10	371	33	28	172	0,92	0,86
11	118	3	1	199	0,98	1,00
13	61	0	2	198	1,00	0,99
14	153	14	4	196	0,92	0,98
15	97	14	3	197	0,87	0,99
16	96	18	2	198	0,84	0,99
17	72	6	2	198	0,92	0,99

ve uç düğümlerden (yapraklar) oluşur. Eğitim verilerine ait öznelitik bilgilerinden yararlanılarak bir karar ağacı yapısı oluşturulmasında temel prensip verilere ilişkin bir dizi sorular sorulması ve elde edilen cevaplar doğrultusunda hareket edilerek en kısa sürede sonuca gidilmesi olarak ifade edilebilir. Bu şekilde karar ağacı sorulara aldığı cevapları toplayarak karar kuralları oluşturur. Ağacın ilk düğümü olan kök düğümünde verilerin sınıflandırılması ve ağaç yapısının oluşturulması için sorular sorulmaya başlanır ve dalları olmayan düğümler ya da yapraklar bulunana kadar bu işlem devam eder. Karar ağaçlarının oluşturulmasındaki en önemli adım ağaçtaki dallanmanın hangi kritere göre yapılacağı ya da hangi öznelitik değerlerine göre ağaç yapısının oluşturulacağıdır. Bu çalışmada C4.5 algoritması kullanılarak sınıflandırma yapılmıştır [15].

### 3. SONUÇLAR

Nöbet teşhisi, Freiburg Veritabanındaki 12 hastanın toplam olarak 49 nöbeti kullanılarak test edilmiştir. 49 nöbete karşılık gelen 123 dakikalık veriler (1475 EEG bölütü) ile sistemin duyarlılığı ölçülmüştür. Sistemin belirliliğinin ölçülebilmesi için toplam 200 dakika nöbet dışı an verisi (2400 EEG bölütü) kullanılmıştır. Duyarlılık,  $DP/(DP + YN)$ ; belirlilik ise  $DN/(DN+YP)$  ve şeklinde hesaplanmaktadır. Doğru pozitif (DP); nöbet anına ait bir pencerenin sınıflandırıcı tarafından nöbet olarak, yanlış negatif (YN); nöbet anındaki bir pencerenin nöbet değil olarak, yanlış pozitif (YP); nöbet dışı anına ait bir pencerenin nöbet olarak ve doğru negatif (DN); nöbet dışı anına ait bir pencerenin nöbet değil olarak sınıflandırılması durumunda ortaya çıkmaktadır.

Tüm hastalar için elde edilen DP, YN, YP, DN, duyarlılık ve belirlilik değerleri, kNN, DVM ve KA için sırasıyla Tablo 1, 2 ve 3'te gösterilmiştir. Tablolardaki sonuçlar tüm hastalar için genel olarak değerlendirildiğinde; kNN sınıflandırıcısının %90,51 duyarlılığa ve %97,25 belirliliğe, DVM sınıflandırıcısının %79,93 duyarlılığa ve %97,63 belirliliğe ve KA sınıflandırıcısının %90,48 duyarlılığa ve %95,38 belirliliğe sahip olduğu görülmektedir. Bu sonuçlar, AKA tabanlı nöbet teşhis sistemi ile, bir nöbetin %90 oranında bir başarı ile teşhis edilebileceğini ve bir teşhis yapıldığında bu teşhisin %95'in üzerinde bir oranla gerçek bir nöbet olacağını göstermektedir.

Bu sistemin eğitim ve test aşamaları, Intel Core2 Duo

Tablo 2: Destek Vektör Makineleri için Sonuçlar

h	DP	YN	YP	DN	Duy	Bel
3	55	29	2	198	0,65	0,99
4	79	1	0	200	0,99	1,00
7	66	21	6	194	0,76	0,97
8	15	47	3	197	0,24	0,99
9	99	7	6	194	0,93	0,97
10	333	71	26	174	0,82	0,87
11	111	10	0	200	0,92	1,00
13	58	3	4	196	0,95	0,98
14	149	18	3	197	0,89	0,99
15	69	42	4	196	0,62	0,98
16	72	42	2	198	0,63	0,99
17	73	5	1	199	0,94	1,00

Tablo 3: Karar Ağaçları için Sonuçlar

h	DP	YN	YP	DN	Duy	Bel
3	75	9	8	192	0,89	0,96
4	79	1	0	200	0,99	1,00
7	74	13	9	191	0,85	0,96
8	34	28	15	185	0,55	0,93
9	102	4	8	192	0,96	0,96
10	376	28	29	171	0,93	0,86
11	115	6	5	195	0,95	0,98
13	58	3	4	196	0,95	0,98
14	156	11	17	183	0,93	0,92
15	102	9	7	193	0,92	0,97
16	109	5	8	192	0,96	0,96
17	76	2	1	199	0,97	1,00

P8600 (2.4 GHz) işlemcili, 4GB RAM ve 64 bit işletim sistemine sahip dizüstü bir bilgisayar ile gerçekleştirilmiştir. Bu bilgisayar ile, 10 saniyelik test verisinin İMF'lerine ayrılması 1.006 saniye, bu İMF'lerden öz niteliklerin çıkarılması işlemi 0.1214 saniye ve bu verilerden sınıflandırma yapılması 0.06 saniye sürmektedir. Bir EEG bölümünün analizi için harcanan toplam süre 1.1874 saniye olup bu süre 5 saniyeden çok daha kısadır ve %50 örtüşme ile 10'ar saniyelik gerçek zamanlı veri analizi için uygun olduğu görülmektedir. Bu sonuçlar AKA yöntemi ile gerçek zamanlı otomatik epilepsi teşhisinin umut vadecici olduğunu göstermektedir.

#### 4. TEŞEKKÜR

Bu çalışma TUBITAK tarafından desteklenen 109E223 nolu proje kapsamında gerçekleştirilmiştir.

#### 5. KAYNAKÇA

- [1] NE Huang, Z Shen, SR Long, MC Wu, SH Shihand Q Zheng, CC Tung, and HH Liu, "The empirical mode decomposition method and the hilbert spectrum or non-stationary time series analysis," in *Proceedings of the Royal Society of London. Series A: Mathematical, Physical and Engineering Sciences*, 1998, vol. 454, pp. 903–995.
- [2] Yan Lu, Jingyu Yan, and Yeung Yam, "Model-based ECG denoising using empirical mode decomposition," in *Bioinformatics and Biomedicine, 2009. IEEE International Conference on*, pp. 191–196.
- [3] KG Chang, "Arrhythmia ECG noise reduction by ensemble empirical mode decomposition," *Sensors*, vol. 10, no. 6, pp. 6063–6080, 2010.
- [4] Min Lei, Guang Meng, and Cheng Jiashui, "Analysis of surface EMG signal based on empirical mode decomposition," in *Rehabilitation Robotics, 2009. ICORR 2009. IEEE International Conf. on*, june 2009, pp. 230–233.
- [5] AO Andrade, S Nasuto, P Kyberd, CM Sweeney-Reed, and FR Van Kanijn, "EMG signal filtering based on empirical mode decomposition," *Biomedical Signal Processing and Control*, vol. 1, no. 1, pp. 44–55, 2006.
- [6] Zuo Ziqiang and S Puthusserypady, "Analysis of schizophrenic EEG synchrony using empirical mode decomposition," in *Digital Signal Processing, 2007 15th International Conference on*, july 2007, pp. 131–134.
- [7] RB Pachori, "Discrimination between ictal and seizure-free EEG signals using empirical mode decomposition," *Res. Let. Signal Proc.*, pp. 14:1–14:5.
- [8] L Orosco, E Laciari, A Garces Correa, A Torres, and JP Graffigna, "An epileptic seizures detection algorithm based on the empirical mode decomposition of EEG," in *Engineering in Medicine and Biology Society. EMBC 2009. Annual International Conference of the IEEE*, pp. 2651–2654.
- [9] Tianqiao Zhu, Liyu Huang, and Xuzi Tian, "Epileptic seizure prediction by using empirical mode decomposition and complexity analysis of single-channel scalp electroencephalogram," in *Biomedical Engineering and Informatics, 2009. BMEI '09. 2nd International Conference on*, oct. 2009, pp. 1–4.
- [10] B Schelter, M Winterhalder, T Maiwald, A Brandt, A Schahad, A Schulze-Bonhage, and J Timmer, "Testing statistical significance of multivariate time series analysis techniques for epileptic seizure prediction," *Chaos*, vol. 16(1), pp. 013108, 2006.
- [11] F. Latifoğlu, A. Güven, U. Durmus, and, and A. Önder, "Denoising of electroretinogram signals using empirical mode decomposition," in *Biomedical Engineering Meeting (BIYOMUT), 15th National*, april 2010, pp. 1–4.
- [12] A.K. Tafreshi, A.M. Nasrabadi, and A.H. Omidvarnia, "Epileptic seizure detection using empirical mode decomposition," in *Signal Proc. and Inf. Tech., ISSPIT. IEEE International Symposium on*, dec. 2008, pp. 238–242.
- [13] RO Duda, PE Hart, and DG Stork, *Pattern Classification (2nd Ed.)*, Wiley-Interscience, 2001.
- [14] N Cristianini and J Shawe-Taylor, *An introduction to support vector machines.*, Cambridge: Cambridge University Pres, 2000.
- [15] JR Quinlan, *C4.5: Programs for Machine Learning*, Morgan Kaufmann, San Mateo, CA, 1993.